

클라우드 기반 양자 컴퓨팅 2024



CONTENTS

Digitalservice Issue Report

디지털서비스 이슈리포트

01	클라우드 기반 양자 컴퓨팅 2024	3
	한상기 (테크프론티어 대표)	
02	기업이 인재 관리를 위한 데이터와 AI를 사용하는가?	14
	Senior Program Manager 김영욱	
03	클라우드에서 서비스 확장하기	22
	정채상 인이지 연구소 기술 책임자	

본 저작물은 디지털서비스 이용지원시스템이 저작권을 보유하고 있습니다.

디지털서비스 이용지원시스템의 승인 없이 이슈리포트의 내용 일부 또는 전부를 다른 목적으로 이용할 수 없습니다.

01 클라우드 기반 양자 컴퓨팅 2024

| 한상기 (테크프론티어 대표)

양자 컴퓨팅을 클라우드에서 지원하는 방안은 2020년 9월에 한 번 다룬 적이 있다.¹⁾ 이후에 새로 등장한 하드웨어와 클라우드 서비스에서 제공한 양자 컴퓨팅 관련 서비스에 대해 업데이트가 필요한 시점이다. 이 글에서는 양자 컴퓨팅의 원리와 역사는 다루지 않으며 그런 자료는 책이나 다른 보고서를 참고하기를 바란다.

시장 조사 기관인 마켓앤마켓에서 나온 전망 보고서를 보면 2024년 13억 달러 수준의 시장이 2029년에는 53억 달러로 연평균 32.7% 증가를 할 것으로 예측한다. 단기, 중기, 장기 시장으로 나누어 보면 단기 시장에서는 양자 오류 정정(QEC)에 초점을 맞추고 있다고 본다.




그림 1 양자 컴퓨팅 시장 규모 예측 [출처: 마켓앤마켓]

양자 컴퓨팅의 클라우드 세그먼트는 온-프레미스보다 더 큰 시장을 갖고 있으며 양자 컴퓨터에 대한 접근과 다른 양자 컴퓨팅 자원에 제공한다. 여기에는 아마존, 마이크로소프트 애저, 구글 클라우드 외에도 양자컴퓨터를 개발하는 전문기업이 제공하는 클라우드 서비스를 포함한다.

1) 한상기, “클라우드 사업자, 양자 컴퓨팅 지원 본격화,” 슬로우뉴스, 2020년 9월 25일

디지털서비스 이슈리포트

아직은 클라우드 서비스와 양자 컴퓨팅 기술 개발, 소프트웨어 환경, 시뮬레이터 등이 기존 클라우드처럼 체계적으로 제공되고 있지는 않으며 전문가들을 위한 개발 환경과 일반 사용자를 위한 환경을 구분하고 있기도 하다. 또한 구글이나 IBM처럼 자사의 양자 컴퓨팅 환경을 중심으로 하는 경우와 외부의 다양한 기업에서 만드는 양자 컴퓨터를 지원하는 방식으로 나누어지고 있다.

마이크로소프트 애저 퀀텀 클라우드 서비스

애저에도 다양한 양자 알고리즘을 구축하고 개선하기 위한 도구와 학습 자원들 그리고 현존하는 양자 컴퓨팅 하드웨어에 대한 접근을 제공하고 있다. 애저에서는 크게 네 가지 기능을 제공한다.

1. 다양한 유형의 양자 하드웨어에 접근을 통해 향후 폴트 톨러런트 양자 시스템을 만들어 갈 수 있도록 한다.
2. Q#, Qiskit 및 Cirq를 지원하는 최신 환경에서 작동하는 오픈 소스 개발 키트를 제공한다.
3. 향후 확장된 양자 머신에서 양자 솔루션을 실행하는 데 필요한 논리적 및 물리적 큐비트 수와 런타임을 이해하도록 한다.
4. 마이크로소프트 런(Learn), 퀀텀 카타스(katas) 자습서, 업계 사례 연구, 대학 커리큘럼 등 세계적 수준의 온보딩 및 교육 리소스를 통해 복잡한 문제를 해결하고 새로운 기술을 개발하도록 지원한다.

또한 애저 양자 리소스 추정기 도구를 사용하면 향후 확장된 양자 컴퓨터에서 양자 애플리케이션을 실행하는 데 필요한 논리적 및 물리적 큐비트 수와 런타임을 추정할 수 있다. 이를 통해 양자 솔루션에 필요한 큐비트 수를 결정하고 큐비트 기술 간의 차이를 평가하고, 미래 규모의 양자 컴퓨터에서 실행할 양자 솔루션을 준비하고 개선하도록 도와준다. 입력으로는 큐비트 파라미터, 양자 오류 정정(QEC) 코드, 여러 예산 등과 양자 중간 표현(QIR) 프로그램을 통해서 제공한다.




그림 2 애저 양자 리소스 추정기 도구들

디지털서비스 이슈리포트

애저에서는 고전 컴퓨팅과 양자 컴퓨팅을 혼합한 하이브리드 양자 컴퓨팅을 제공해 적응형 위상 추정과 같은 새로운 하이브리드 알고리즘을 발견할 수 있으며, 고전적 계산을 위한 알고리즘을 구축한 다음 물리적 큐비트가 일관된 상태에서 반복 및 적응할 수 있도록 한다.

종합적인 리소스는 애저 퀀텀 웹사이트에서 찾아볼 수 있으며 코파일럿을 이용해 개념 이해를 하거나 블로그, 문서, 동영상 등을 통해 전문가들에게 정보를 얻을 수 있다.



그림 3 애저 퀀텀 웹사이트

애저 퀀텀은 애저 양자 개발 키트(QDK)를 제공하며 이를 사용해 Q# 양자 프로그램을 작성하고, 코드 디버깅을 수행, 실시간 코드 피드백을 받고, 원하는 양자 컴퓨터 머신을 선택할 수 있다. QDK는 내결함성 양자 컴퓨팅(FTQC)을 위한 유일한 개발 키트라고 한다.

애저에서 지원하는 양자 컴퓨팅 하드웨어는 다음과 같다.

- 퀀텀의 시스템 모델 H1: 갇힌(포획) 이온 양자 컴퓨터로 완전 연결 20큐비트를 갖고 있다.
- 이온큐(IONQ) - 갇힌 이온 양자 컴퓨터로 11~23개의 완전히 연결된 큐비트 범위에서 동적으로 재구성할 수 있는 다중 시스템을 통해 모든 쌍 간에 2큐비트 게이트를 실행할 수 있다. 아리아, 포르테가 있으며 포르테 엔터프라이즈와 템포를 개발 중이다. 애저뿐만 아니라 구글 클라우드, AWS에서도 지원하며 자체 이온큐 양자 클라우드에서도 지원한다.
- QCI - 초전도 방식으로 오류 감지 및 제어 기능이 내장된 듀얼 레일 캐비티 큐비트를 사용하는 풀 스택 시스템이다.
- 이 외에도 초전도 방식의 리게티(Rigetti), 중성 원자 방식의 파스칼(PASQAL) 등이 있다.

디지털서비스 이슈리포트

애저가 사랑하는 풍부한 개발 환경의 강점은 다음과 같다.

- 가장 인기 있는 양자 SDK: Q#, Qiskit, Cirq
- 한 번 작성해 다종의 하드웨어 아키텍처에서 실행할 수 있다.
- 네이티브 회로를 QPU로 전송할 수 있다.
- 세계적 수준의 샘플과 커리큘럼에 대한 접근
- 몇 분 이내에 시작할 수 있는 주피터 노트북에 접근
- 다양한 시뮬레이터와 에뮬레이터를 탐색할 수 있다.

이를 사용하는 사례로는 골드만 삭스가 Q#으로 알고리즘을 구현해 주식이나 파생 상품 가격 계산에 필요한 양자 하드웨어 리소스 추정을 시행했으며, 에네오스(ENEOS)는 지속 가능한 수소 연료에 관해 연구했다고 한다.

구글 클라우드의 양자 컴퓨팅 지원

구글은 양자 클라우드를 제공하면서도 동시에 양자컴퓨터를 개발하는 회사이고 양자 AI 팀을 별도로 만들어 운영하고 있다. 클라우드에서는 경험이 많은 양자 컴퓨팅 전문가나 흥미를 갖고 사용하고자 하는 초보자 모두에게 도구와 자원을 제공하고 있다. 또한 구글 양자 AI 팀이 개발한 양자 프로세서에 접근을 제공하고 있다.

구글이 양자 컴퓨팅에 참여한 것은 2006년 캐나다의 디-웨이브(D-Wave)에 출자를 하면서인데 이때부터 양자 컴퓨팅은 AI와 암호 분야에서 가진 잠재력에 주목했기 때문이다. 구글 양자 AI 팀은 나사(NASA)와 USRA(대학 우주 연구 협회)와 협력으로 2014년에 설립했고 초기에는 512큐비트를 갖는 두 대의 디-웨이브로 시작했으나 양자 어닐러(Annealer)의 한 종류의 디-웨이브 시스템은 기능이 제한적인 것으로 드러난 후 2015년 초전도 회로를 기반으로 하는 양자 프로세서 개발을 위해 캘리포니아대학교 산타바바라 캠퍼스(UCSB)와 파트너십을 맺었고 이것이 구글의 양자 컴퓨팅 전략의 전환점이 되었다.

양자 클라우드 초기에는 2019년 양자 우위를 달성한 54-큐비트 프로세서인 시카모어 양자 프로세서가 양자 클라우드 플랫폼의 기반을 마련했다.²⁾ 시카모어는 현존 최고 성능 컴퓨터가 만 년 걸릴 작업을 200초 안에

2) Quantum Zeitgeist, "Google Quantum Cloud," May 20, 2024

디지털서비스 이슈리포트

계산해 냄으로써 처음으로 양자 컴퓨터가 일반 컴퓨터보다 특정 분야에서는 압도적일 수 있음을 보였다. (그러나 나중에 IBM은 일반 컴퓨터로도 2.5일 만에 할 수 있는 일이라고 이에 대해 비판했다.)



그림 4 구글 시카모어

구글 양자 클라우드는 양자 컴퓨팅을 위한 플랫폼이자 양자 연구 및 교육을 위한 허브이다. 튜토리얼, 연구 논문, 데이터 세트 등 다양한 리소스를 제공하여 사용자가 양자 컴퓨팅의 세계를 이해하고 탐구하는 데 도움을 준다. 이러한 리소스는 초보자부터 숙련된 연구자까지 다양한 사용자를 위해 설계되어 양자 컴퓨팅을 위한 종합 플랫폼으로 만들어 준다.

또한 구글 양자 클라우드는 사용자가 실제 양자 하드웨어에서 실행하기 전에 양자 알고리즘과 회로를 테스트할 수 있는 쿼텀 엔진이라는 시뮬레이터를 제공한다. 쿼텀 엔진은 노이즈 및 기타 양자 현상의 영향을 포함하여 양자 프로세서의 동작을 정확하게 모방하도록 설계되었고, 이 기능은 양자 프로그램을 디버깅하고 양자 알고리즘을 최적화하는 데 유용하다.

구글 양자 클라우드의 주요 기능 중 하나는 양자 머신 러닝 모델을 빠르게 프로토타이핑할 수 있는 오픈 소스 라이브러리인 텐서플로우 쿼텀(TFQ)과의 통합이다. TFQ는 양자 데이터 세트를 생성하고, 양자 모델을 설계하고, 고전적인 머신 러닝 기술을 사용하여 이러한 모델을 훈련할 수 있는 도구를 제공한다. 이러한 통합을 통해 사용자는 머신 러닝 분야에서 양자 컴퓨팅의 성능을 활용하여 연구 및 개발의 새로운 가능성을 열 수 있다.

구글 양자 컴퓨팅 서비스 페이지를 보면 구글의 양자 컴퓨팅 하드웨어에 대한 접근을 제공하는 서비스라고 정의한다. 프로그램은 Cirq라는 오픈 소스 양자 컴퓨팅 프로그래밍 언어로 작성했고, 이를 산타바바라에 있는 구글의 양자 컴퓨팅 랩 안에 있는 양자 컴퓨터로 보내서 동작시킨다고 한다.

디지털서비스 이슈리포트

오픈 소스 Cirq 언어는 특히 구글 양자 컴퓨팅 이니셔티브 영역 내에서 양자 컴퓨터의 프로그래밍 및 시뮬레이션에서 중추적인 역할을 한다. Cirq는 구글 양자 프로세서에서 양자 회로를 생성, 편집, 호출하기 위해 특별히 설계된 파이썬 라이브러리로, 연구원과 개발자가 양자 알고리즘을 구성 및 최적화하고, 기존 컴퓨터에서 동작을 시뮬레이션하며, 궁극적으로 실제 양자 하드웨어에서 실행할 수 있는 포괄적인 프레임워크를 제공한다.

Cirq는 노이즈 중간 규모 양자(NISQ) 회로의 생성, 편집, 호출을 위해 명시적으로 맞춤화되어 있다. NISQ 회로는 일반적으로 큐비트가 적고 노이즈에 영향을 받는 최신 양자 장치에서 실행할 수 있는 양자 회로의 한 종류이다. Cirq의 설계 철학은 NISQ 시대에 초점을 맞추고 있어 구글 양자 클라우드와 함께 작업하기에 이상적인 도구이다.

구글 양자 클라우드 서비스는 양자 회로와 양자 계산 결과를 시각화할 수 있는 도구도 제공한다. 이러한 도구에는 양자 회로의 동작을 시뮬레이션할 수 있는 양자 회로 시뮬레이터와 양자 계산의 결과를 그래픽 형식으로 표시할 수 있는 양자 데이터 시각화 도구를 포함한다. 이를 이용하면 사용자가 양자 회로의 동작을 이해하고 양자 프로그램을 디버깅하는 데 도움이 될 수 있다.

협업과 연구를 위한 플랫폼도 제공하는데, 여기에는 양자 회로를 작성, 실행, 시각화할 수 있는 온라인 인터페이스인 켄텀 플레이그라운드와 양자 알고리즘 및 애플리케이션을 공유하고 협업할 수 있는 플랫폼인 켄텀 허브를 포함하고 있다. 양자 클라우드는 단순한 서비스가 아니라 양자 컴퓨팅의 경계를 넓혀가는 연구자, 개발자, 애호가들의 커뮤니티이다.

양자 물리학 및 머신 러닝의 교차점에서 새롭게 떠오르는 학제 간 연구 분야인 양자 머신 러닝(QML)도 양자 클라우드에서 활용한다. QML 알고리즘은 기존 알고리즘보다 대량의 데이터를 더 효율적으로 분석할 수 있다. 이는 대용량 데이터 세트가 표준인 생물정보학 및 유전체학에서 특히 유용하다. 구글 양자 프로세서는 이러한 알고리즘을 가속하여 더 효율적이고 효과적으로 만들 수 있다.

또 다른 혁신은 양자 오류 정정(QEC)으로, 디코히어런스와 기타 양자 잡음으로 인한 오류로부터 양자 정보를 보호한다. QEC는 신뢰할 수 있는 대규모 양자 컴퓨터를 개발하는 데 필수적인데, 구글 양자 클라우드는 양자 프로세서의 안정성과 확장성을 개선하기 위해 QEC 기술을 적극적으로 연구 및 개발하고 있다.

구글이 생각하는 향후 양자 컴퓨팅 로드맵은 아래 그림과 같은데, 이를 보면 이제 두 번째 단계를 구현하는 수준임을 알 수 있다. 구글이 구현한 양자 오류 큐비트(QEQ)는 논리적 큐비트로 말하기도

디지털서비스 이슈리포트

하는데 2023년 처음으로 논리적 큐비트의 프로토타입을 데모했다. 이는 QEC로 알려진 방식을 통해 큐비트 수를 늘림으로써 오류를 줄이는 것이 가능하다는 것을 보였다.



그림 5 구글 양자 컴퓨팅 로드 맵 [출처: 구글 양자 AI]

암호화 분야에서 구글 양자 클라우드에 양자 프로세서에 대한 액세스를 제공함으로써 양자 컴퓨터에 저장하는 암호화 방법을 개발하는 분야인 포스트 퀀텀 암호학(PQC) 연구를 가속화하고 있다.

2022년, 구글 퀀텀 AI는 회로 검증 및 프로세서 충실도 등 실험실에서 양자 컴퓨터 중 하나를 프로그래밍하는 경험을 시뮬레이션하기 위해 개발된 양자 가상 머신(QVM)을 출시했다. 이 기계는 시카모어 프로세서의 측정값(큐비트 붕괴, 위상, 게이트 및 판독 오류)을 물리학 연구팀의 모델과 결합하여 작동하며, 이 모델을 사용하여 양자 프로세서와 유사한 출력을 시뮬레이션할 수 있다.

IBM 양자 플랫폼 3)

2016년에 시작한 IBM 양자 경험(Experience)이라고 불렀던 서비스를 재구성하여 새로 제공하는 클라우드 기반의 양자 컴퓨팅 서비스이다. 여기에는 IBM의 프로토타입 양자 프로세서 세트, 양자 연산에 대한 튜토리얼 세트, 대화형 교과서 액세스를 포함한다.

서비스에는 20개가 넘는 기기가 있으며 그 가운데 6개는 일반 사용자도 사용할 수 있다. IBM의 양자 프로세서는 초전도 트랜스몬 큐비트로 구성되어 있으며, 토마스 J. 왓슨 연구 센터에 있는 희석 냉장고에 보관되어 있다. IBM은 1,121큐비트를 갖는 콘도르(Condor) 양자 프로세서를 2023년 12월에 발표했다. 이는 교차 공명 게이트 기술을 기반으로 만든 초전도 양자 프로세서이다.

3) IBM의 양자 컴퓨팅 블로그 참조. <https://www.ibm.com/quantum/blog/quantum-roadmap-2033>

디지털서비스 이슈리포트




그림 6 IBM 양자 플랫폼 초기 화면

사용자는 양자 회로 모델을 통해 양자 프로세서와 상호 작용한다. 회로는 쿼텀 컴포저를 사용해 그래픽으로 만들거나 쿼텀 랩의 주피터 노트북을 사용해 프로그래밍 방식으로 만들 수 있다. 회로는 키스킷(Qiskit)을 사용하여 생성되며, 실제 양자 시스템에서 실행하기 위해 OpenQASM으로 컴파일할 수 있다. 키스킷은 2024년 2월 버전 1.0을 완료했다.

양자 프로그램의 구조를 설명하는 프로그래밍 템플릿이자 대규모 양자 알고리즘과 애플리케이션을 구축하기 위한 논리적 프레임워크인 키스킷 패턴을 소개했다. 사용자는 키스킷 패턴이 제공하는 구성 가능성, 컨테이너화, 추상화를 활용하여 기본 빌딩 블록 모음에서 양자 알고리즘과 애플리케이션을 원활하게 생성하고, 쿼텀 서버리스와 같은 이기종 컴퓨팅 인프라를 사용하여 해당 패턴을 실행할 수 있다.

IBM은 양자 플랫폼에서 실행되는 강화 학습을 사용한 세계 최초의 회로 컴파일 서비스를 통해 양자 컴퓨팅과 AI를 연결하고 있다. 또한 IBM의 엔터프라이즈 AI 플랫폼인 왓슨X를 통해 양자 코드 프로그래밍에 생성형 AI를 사용하는 분야를 개척하고 있다. 왓슨X를 통해 제공하는 생성형 AI가 키스킷의 양자 코드 개발을 자동화하는 데 어떻게 도움이 되는지 보이고자 하고 있고, 200억 개의 파라미터 코드 파운데이션 모델인 그라나이트(Granite)의 미세 조정을 통해 이를 달성했다.

IBM은 2024년 5,000 게이트를 가진 헤론(Heron)을 시작으로 2029년에는 200큐비트 이상에서 1억 게이트를 실행하는 스타링 프로세서를 만들 예정인데 여기에는 그로스(Gross) 코드라는 새로운 방식의 오류 정정을 채택할 계획이다.

디지털서비스 이슈리포트

아마존 브라켓

아마존 브라켓은 양자 컴퓨팅을 위한 과학 연구 및 소프트웨어 개발 속도를 높이기 위해 설계된 완전 관리형 양자 컴퓨팅 서비스이다.




그림 7 아마존 브라켓 서비스 개념도

브라켓에서 지원하는 양자 컴퓨터는 초전도, 갇힌 이온, 중성 원자 방식 등 다양하며 이온큐, IQM, 리게티, QuEra 등이 있다. 브라켓 다이렉트를 통해 온디맨드로 또는 디바이스 예약을 사용해 양자 워크로드를 시행할 수 있으며, 다양한 시스템 성능을 비교하고 애플리케이션에 가장 적합한 하드웨어 시스템을 선택하도록 하고 있다.

브라켓 튜토리얼은 깃허브에 공개되어 있으며 양자 회로를 시뮬레이터에서 동작하기, QPU 장비에서 동작하기, 양자 회로의 분석을 위해 깊이 탐구하기, 아마존 브라켓 SDK를 통해 초밀도 코딩 프로토콜 구현하기 등을 소개한다.

첨단 회로와 알고리즘에는 그로버 알고리즘, 양자 진폭 증강 (QAA) 알고리즘, 양자 푸리에 변환, 양자 위상 추정(QPE), 양자 난수 생성기(OENG), 사이몬 알고리즘 등이 있으며, 하이브리드 알고리즘에는 AQOQ, VQE, VQE 전도, 횡단 이성 모델 등에 대한 튜토리얼을 제공한다.

브라켓 시뮬레이터는 네 종류가 있는데, 작은 규모는 무료이며 로컬 머신에서도 동작할 수 있으나 대규모는 온 디맨드 시뮬레이터를 사용해야 한다. 34 큐비트까지 완전 상태 벡터 시뮬레이션은 SV1, 16큐비트까지 회로의 노이즈를 시뮬레이션하는 것은 DM1, 50큐비트까지 양자 회로를 위한 것은 TN1이라고 한다.

디지털서비스 이슈리포트

양자 컴퓨팅 결과는 개별 샘플, 사용자 지정 관측량, 개별 진폭 혹은 완전 상태 벡터를 포함해 시뮬레이션 작업에 대한 다양한 유형의 결과를 선택할 수 있다. 시뮬레이터는 정확한 결과를 계산하거나 양자 컴퓨터의 동작을 에뮬레이션하는 측정 샘플을 반환할 수 있다.

아마존 브라켓 파이썬 SDK는 브라켓을 통해 양자 컴퓨팅 하드웨어 장치와 상호 작용하는 데 사용할 수 있는 프레임워크를 제공하는 오픈 소스 라이브러리이다. 자세한 정보는 깃허브에 올라와 있다.⁴⁾

브라켓에서는 양자 미분 프로그래밍 개념을 기반으로 구축된 오픈 소스 소프트웨어 프레임워크인 페니레인(PennyLane)을 지원하여 하이브리드 양자 클래식 또는 변형 알고리즘을 구축하고 실행할 수 있도록 지원하고 있다. 이 접근 방식을 사용하면 양자 화학, 양자 기계 학습 및 최적화의 계산 문제에 대한 솔루션을 찾기 위해 기계 학습 신경망을 훈련하는 것과 동일한 방식으로 양자 회로를 학습시킬 수 있다. 페니레인은 브라켓에 최적화되어 있으며 파이토치 및 텐서플로우 등 익숙한 도구에 대한 인터페이스를 제공해 양자 회로를 빠르고 쉽게 직관적 방식으로 훈련할 수 있다.

아마존은 알고리즘 개발과 지원을 위한 AWS 클라우드 크레딧을 제공하는데 양자 컴퓨팅 연구자들에게도 서비스로서의 과학이라는 관점에서 제공하고 있다. 아마존 브라켓의 내용은 대부분 지난 글에서 소개한 것을 크게 벗어나지 않기 때문에 2020년 9월 원고를 참고하기를 바란다.

기타 전문기업들

양자 컴퓨터를 만드는 전문기업들도 단독으로 클라우드 서비스를 제공한다. 리게티(Rigetti) 컴퓨팅은 QCS라는 양자 컴퓨팅 클라우드를 제공하고 있으며 마찬가지로 리게티 양자 프로세서에 대한 접근, 양자 시뮬레이터, 양자 프로그래밍 환경을 제공하고 있다. 이 플랫폼은 양자 알고리즘 개발 및 테스트와 리게티의 양자 하드웨어에서 이러한 알고리즘을 실행할 수 있도록 지원한다. 또한 사용자가 양자 컴퓨팅과 기존 컴퓨팅의 강점을 모두 활용할 수 있는 하이브리드 양자-클래식 컴퓨팅 솔루션을 제공한다.

이온큐는 이온큐 양자 클라우드를 따로 제공하는데 이는 오픈 API를 기반으로 하고 있으며, 주요 SDK를 모두 지원한다. 여기에는 Qiskit, QCW Forge, Cirq, ProjecQ, CQ tket, 페니레인, Q#, 텐서플로우 등이 있다. 이온큐 QPU는 API를 통해서 접근할 수 있는 노이즈 있는 시뮬레이터와 아이디어 상태 시뮬레이터 모두를 제공한다.

4) <https://github.com/amazon-braket/amazon-braket-sdk-python>

디지털서비스 이슈리포트

디-웨이브 역시 Leap이라는 클라우드 기반 양자 컴퓨팅 서비스를 제공하고 있다. Leap은 사용자에게 디-웨이브의 양자 어닐링 프로세서, 양자 애플리케이션 환경, 양자 학습 리소스에 대한 액세스를 제공한다. Leap에는 어드밴티지, 하이브리드 솔버, 오션 소프트웨어 개발 키트, 라이브 코드, 데모, 학습 리소스, 활발한 개발자 커뮤니티에 대한 액세스를 포함한다. 완전히 새로워진 제약 이차 모델 솔버(constrained quadratic model solver)는 문제 제약 조건을 직접 통합하여 사용자가 제약된 문제를 보다 단순하고 네이티브하게 표현할 수 있도록 지원한다. 디-웨이브는 업계 최초로 CQM 솔버가 연속형 변수를 지원하여 더욱 다양한 제약 문제 유형을 더 잘 표현할 수 있다고 말하고 있다. 오션 도구 모음은 디-웨이브 깃허브에서 확인할 수 있다.

02 기업이 인재 관리를 위한 데이터와 SI를 사용하는가?

| Senior Program Manager 김영욱

사람이 가장 중요한 자산이다?

“사람이 가장 중요한 자산이다.” 기업 세계에서는 너무나 흔히 잘 사용하는 말이다. 하지만 그렇다면 기업에서 왜 아직도 수많은 인재 관련 의사 결정이 직관에만 의존하는 것일까? 관리자는 직원 관련 의사 결정에 있어 '늘 최선을 다해야 한다'는 기대를 한다. 팀원이 승진할 준비가 되었는지를 결정하거나, 조직 KPI에 대한 팀의 멤버 각각의 영향력을 평가하거나, 신규 채용의 적절한 시기를 정확히 파악하는 등 사람 관련 중요한 의사 결정은 컨설팅 회사의 보고서나 개인적인 경험, 우연에 맡겨서는 안 된다는 사실에는 모두 동의한다. 하지만 예를 들어 “직원들이 회사를 떠나는 가장 큰 이유는 무엇인가?”와 같은 기업을 운영하는 데 가장 근본적인 질문에는 답을 하기 쉽지 않다.



그림 8 기업 내 관리자의 업무 스트레스 요인 5가지 (출처: visier.com)

디지털서비스 이슈리포트

점점 더 데이터 중심적이고 AI와 자동화된 세상에서 관리자는 성공을 위해 더 많은 도구와 정보가 필요하다. HR 분석 SaaS 솔루션을 제공하는 비지어(visier.com) 리포트⁵⁾에 의하면 비즈니스 성과 창출에 관한 압박감이 관리자가 느끼는 가장 높은 스트레스 요인으로 나타났으며, 이런 업무 스트레스로 인해 절반에 가까운 44%의 관리자가 본인이 그 역할에 준비되지 않았거나 기업으로부터 지원을 받지 못한다고 느껴 이직을 고려한 적이 있다고 한다.

이런 상황에서 기업의 최고 인사 책임자(CHRO)에게는 다음과 같은 질문을 던져볼 수 있다. “기업이 어떻게 관리자 효율성을 높이고 새로운 기술을 활용하여 보다 자신감 있는 의사 결정을 유도하고 전문성을 유지할 수 있을까?”

같은 조사에서 관리자들은 생산성을 높이고 인재 관련 데이터의 처리와 이해에 도움을 제공할 수 있는 생성형 AI 사용에 큰 기대가 있었고, 이것은 CHRO가 이런 유형의 서비스 사용을 통해 인재 분석에 대한 접근성과 데이터 민주화를 향상할 수 있다는 생각을 가져다주었다. 이에 따라 AI 기술과 데이터 효율성을 통해 기업에서 관리자의 의사 결정 품질과 업무 효율성을 향상할 수 있는 4가지 요소에 대해 알아보고자 한다.

1. 더 많은 인사 데이터(people data)에 접근할 수 있게 한다.

많은 기업에서 도움이 될 수 있는 인사 데이터를 공유하고 사용하는 것에 대해 전통적으로 저항감이 있다. HR 부서는 사람에 관한 정보에 대해 폐쇄적인 접근 방식을 취한다. 내부적인 정책은 주로 비즈니스 전략과 최종 결과보다는 규정 준수와 프로세스에 중점을 두었다. HR팀은 일반적으로 비즈니스에 필요한 인재를 찾고, 인사 정책을 수립하고, 규정 준수를 보장하는 업무를 담당하고, 성과 관리는 경영진의 몫이다. 그런 이유로 비즈니스 성과와 직원의 성과를 연결하는 데는 간극이 존재한다.

급여부터 온보딩, 성과 관리에 이르기까지 모든 분야에서 디지털화가 이루어지고 있음에도 불구하고 이러한 데이터는 HR 내부에 고립된 채 더 넓은 조직과 리더가 접근할 수 없는 상태로 남아 있는 경향이 있다. 게다가 인사 데이터는 서로 다른 시스템에 흩어져 있는 다양한 장소에 존재한다는 사실도 있다. 매출과 수익, 생산, 고객 만족도 등 모든 비즈니스 데이터는 완전히 별개의 플랫폼에서 다루어진다. 직원과 비즈니스 성과를 연결하는 데이터는 눈에 보이지 않거나, 지휘 체계상에서 공유되지 않거나, 변화를 취하지 않는다. 2022년 현재 비즈니스 인텔리전스 및 분석 도구를 사용하는 직원은 25%에 불과하며, 이는 7년 동안 거의 변화가 없는 수치이다.⁶⁾

5) visier.com, “New Manager Effectiveness Research”

디지털서비스 이슈리포트

예를 들어보자. 한 광산 회사가 근로자의 업무 중 산업 재해 부상으로 어려움을 겪고 있다. 경영진으로서의 뭔가 빠른 조치가 필요하다는 생각에 따라 안전 교육을 두 배로 강화하면 상황을 반전시킬 수 있다고 믿는다. 그러나 근로자에 대한 실제 데이터는 다른 이야기를 들려준다. 결과적으로 문제를 해결하는 것은 직원들이 안전 동영상을 더 많이 시청하게 하는 것과는 거의 관련이 없으며, HR 데이터는 이러한 사고와 피로 사이의 직접적인 연관성을 보여준다. 너무 긴 교대 근무, 너무 적은 휴일, 심지어 나이에 따른 낮은 체력 수준까지, 사원 데이터는 패턴이 분명하다.

채용부터 급여, 병가, 성과 및 교육에 이르기까지 직원에 대해 수집된 풍부한 정보, 즉 사람 데이터는 종종 재무 및 기타 비즈니스 데이터에 비해 부차적인 것으로 무시되고 소외되는 경우가 많다. 많은 데이터 책임자와 회사 경영진은 너무 '민감한' 정보라고도 말한다. 하지만 비즈니스 운영 비용과 모든 결과의 대부분을 사람이 차지하므로 이 데이터의 의미를 빠르게 찾아야 한다.

관리자는 더 많은 직원 데이터에 접근하기를 원하며, 자신감 있고 효과적인 리더가 되기 위해서는 이러한 정보가 매우 중요하다고 생각한다. 관리하는 직원이 많을수록 더 많은 데이터가 성공에 기여할 수 있는 기회는 높아진다. 인사 관련 데이터에 대한 접근성이 향상된다면 기대되는 혜택은 다음과 같다.

- 채용, 승진 등에 대한 의사 결정 개선
- 직원 참여도 및 사기 향상
- 직원 생산성 및 효율성 향상

이런 데이터를 공유할 수 있는 AI 대화형 인터페이스는 단일 창구에서 시작되어야 한다. 적절한 위치에서 적절한 정보에 액세스할 수 있으므로 직원들은 셀프서비스를 통해 스스로 질문에 답할 수 있도록 해야 한다. IT, HR, 법무, 시설, 조달 등 복잡한 업무와 주제를 다루면서도 더 많은 검색, 지식 콘텐츠 등에 생성형 AI 기능을 사용하여 정보의 접근을 빠르게 하는 것만큼 사례의 편향성을 줄이는 노력이 필요하다.

2. 인력 영향력의 격차 이해하기

관리자별로 인사 데이터의 접근성에는 상당한 격차가 존재한다. 비지어와 딜로이트의 공동 리포트⁶⁾에 따르면 최고 경영진의 64%가 직원 유지 관리 능력에 대해 자신감을 느끼고 있지만, 관리자의 36%만이

6) Eckerson Group, "New Study Identifies Drivers of BI and Analytics Adoption in Companies Today", Mar 30, 2022

7) Visier x Deloitte, "The Future of People Management", Sep, 2023

디지털서비스 이슈리포트

같은 생각을 하는 것으로 나타났다. 이러한 '인력 영향력 격차'는 데이터 기반 의사 결정과 관련 있다. 마이크로소프트의 업무 동향 보고서⁸⁾는 관리자의 53%가 번아웃을 느끼고 있다고 한다. 관리자들은 거의 하룻밤 사이에 역할을 바꾸고 있는 AI의 물결에 대처해야 하는 복잡한 시기이지만, 수많은 문제를 처리할 준비가 제대로 되어 있지 않은 것으로 나타났다.

더 나은 인사 데이터는 관리자가 이러한 문제를 파악하고 해결책을 모델링하는 데 도움이 될 수 있다. 문제는 이러한 데이터가 가장 필요한 사람들에게 전달되는 데 있어 항상 큰 걸림돌이 있었다는 점이다.

최신 HR 서비스 톨과 인프라 성장 이면에는 개인정보 보호와 보안에 대해 매우 타당한 우려가 자리 잡고 있다. 직원 데이터는 매우 민감한 데이터이고, 신원 도용에 대한 우려가 커지는 만큼 개인정보 보호 및 보안 규정이 강화됨에 따라 기업은 직원에 대해 수집한 정보를 철저히 관리해야 한다.

하지만 인사 데이터가 역사적으로 비밀로 유지되어 온 또 다른 이유는 바로 조직의 역학 관계이다. HR은 인사 데이터의 궁극적인 수호자이자 해석자인 동시에 운영, 채용, 문화, 보상에 관한 정책을 수립하는 미션 크리티컬한 역할을 담당한다. 하지만 이러한 정책을 일상적으로 실제로 실행하는 것은 각 부서의 관리자이며, 이를 위해서는 이러한 각 부서 관리자가 그 인사이트에 액세스할 수 있어야 한다.

자신의 팀이 비즈니스/재무 목표에 어떻게 기여하고 있는지와 관련된 데이터에 액세스할 수 있는 기업은 거의 없으며, 다양성, 형평성, 포용성 지표와 이직률 지표 또는 그 예측 데이터도 거의 해당 매니저들이 추적하고 있지 않다. 다행히도 보안에 대한 우려와 관리자의 가시성 요구 사이의 균형을 맞출 수 있는 도구는 시장에 많다. 직원의 성과, 참여도, 커리어 궤적에 관한 중요한 정보는 필요한 일선 관리자에게만 제공될 수 있으며, 개인, 의료 및 신상 데이터는 HR 부서 내에서 안전하게 보호할 수 있다. 관리자가 이러한 인사이트에 액세스할 수 있게 있고 학습된 AI 모델을 통해 구성원의 미래 경력 관리를 주도할 수 있는 기업의 경쟁력은 그 자체로 혁신이 될 수 있다.

기업 조직에서 커뮤니케이션은 매우 중요하다. 수많은 부서에 수많은 사람이 흩어져 있으므로 정보가 어떻게 개인에게 전달되는가에 따라 큰 차이를 만들 수 있다. 직원들이 정보를 얻을 수 있는 단일 소스로 유도해야 할 뿐만 아니라, 해당 포털은 직원들이 관심을 가질 만한 주제를 집중 조명해야 한다.

- 서비스 및 커뮤니케이션 경험 통합: 사용자 경험을 염두에 두고 구축된 단일 통합 직원 포털은 모든 커뮤니케이션의 중심이 된다.

8) Microsoft, "Hybrid Work Is Just Work. Are We Doing It Wrong?", Sep, 2022

디지털서비스 이슈리포트

- 통합 인터페이스: 직원이 필수 서비스를 요청하기 위해 수십 개의 시스템을 탐색할 필요가 없어야 한다. 이러한 쿼리를 한곳에 모아 적절한 팀으로 라우팅하는 처리가 필요하다.
- 프로필 기준에 따라 콘텐츠와 서비스를 개인화: 직원은 다양하다. 생성형 AI를 활용하여 정보를 맞춤화하고, 콘텐츠를 추천하고, 가장 관련성이 높다고 판단되는 내용을 기반으로 경험을 제공한다.
- 타게팅 된 콘텐츠 캠페인 제공: 신속하게 대응해야 할 때는 변화의 영향을 받는 직원에게 커뮤니케이션과 주요 정보를 푸시한다. 이것은 잘못된 정보와 불만을 모두 줄일 수 있다.

3. 데이터 활용을 통한 비즈니스 성과 창출

과거에는 '인재 데이터 분석'은 기업이 사용할 수 있는 데이터로 제한되었다. 단순한 참여도 설문조사와 기본적인 벤치마킹만으로는 직원 동향의 '이유'나 직원들이 내린 결정이 향후에 미칠 영향에 대한 가시성은 거의 없었다. 오늘날 직원과 운영의 여러 정보를 통합할 수 있게 된 기업은 직원에 대한 전체적인 그림과 미묘한 차이를 파악할 수 있으며, 직원들이 수익에 미치는 영향도 파악할 수 있다. 이런 종류의 데이터는 기업의 급여 철학과 성과 데이터 및 업계 벤치마킹을 결합하여 직원 급여와 관련한 적절한 숫자를 도출할 수 있는 스마트 보상 도구와 같은 시스템을 구축할 수 있는 정보를 제공한다. 인과 관계 분석을 통해 관련 영향 요인을 조사하여 직원이 퇴사한 이유를 명확하고 정량적인 경고 신호를 통해 파악할 수 있다. 한편, 최신 모델링 도구는 개인의 기술과 관심사, 회사의 니즈에 따라 개인의 경력 궤적을 예측하는 데 도움을 줄 수 있으며, 이는 자동화 및 인공지능으로 인한 노동력의 혼란에 직면했을 때 귀중한 인사이트가 될 수 있다.

NAME	GUIDANCE	TOTAL CASH
 Sophia Clark	same as guidance	\$120,000
 Joyce Lee	↑ 5% than guidance	\$107,000
 Jon Yang	same as guidance	\$125,000

그림 9 보상 플래닝에 AI를 적용한 서비스 (출처: 래티스 lattice.com)

디지털서비스 이슈리포트

이러한 데이터와 도구가 관리자의 손에 맡겨지면 직원의 행복과 생산성을 높이는 데 필수적일 뿐만 아니라 비즈니스 자체의 수익 가치도 높일 수 있다. 반대로 이러한 데이터를 확보하지 못하면 관리자는 주요 의사 결정에 대한 정보를 얻지 못해 실수, 비효율성, 기회를 놓칠 수 있는 위험에 노출된다.

이러한 실수는 단순히 인력 손실에만 그치지 않고 비용이 발생한다. 중간급 직원 한 명을 교체하는 데 드는 비용이 연봉의 1.5배에 달한다는 점을 고려하면 그 이점이 명확하다. 조사에 따르면 직원 10,000명의 회사에서 데이터를 민주화하면 약 4억 달러의 비용을 절감하고 2억 달러의 새로운 수익을 창출할 수 있는 것으로 나타났다. 이러한 혜택은 이직 비용 감소, 관리자 시간 절약, 고객 서비스, 혁신 및 협업 개선 등의 형태로 회사 전반에 걸쳐 나타난다.

관리자들은 생성형 AI를 현재의 다음과 같은 의사 결정 문제를 해결할 수 있는 솔루션으로 전망한다.

- 특정 직원/팀에 대한 성과 및 생산성 인사이트 확보
- 팀의 성과와 보상의 상관관계 파악
- 팀에서 퇴사할 위험이 있는 사람 파악
- 다양성, 형평성, 포용성에서 개선이 필요한 잠재적 영역 파악
- 인재 확보 전략

4. 모두가 데이터 과학자가 아니다.

관리자는 더 많은 데이터를 이용할 준비가 되어 있지만, 데이터에 액세스하고 사용하는 방법을 반드시 알고 있지는 않다. 관리자 대부분이 의사 결정을 위해 데이터를 가져올 때 적어도 한 가지 이상의 문제점을 경험하는데 대표적으로 프로세스에 시간이 오래 걸리고 데이터에 액세스하기 어렵다는 점이다. 또한 데이터를 해석하기 어려운 면이 있다. 그 이유는 데이터가 오래되었거나, 불완전하거나, 부정확한 면도 있다. 데이터 분석가가 인사이트를 수집하고 분석을 수행할 때까지 기다리는 것은 관리자가 변화하는 상황에 신속하게 대응하고 적시에 정보에 입각한 의사 결정을 내리는 데 방해가 된다. 인사 관리자가 직장에서 더 현명하고 확실한 의사 결정을 내리려면, CHRO는 데이터 액세스를 민주화하고 관리자에게 데이터 검색과 해석을 간소화하는 셀프서비스 분석 도구를 제공해야 하며, 인사이트를 지나치게 복잡하게 만들지 않는 데 중점을 두어야 한다. 데이터에 더 쉽게 액세스하고 해석할 수 있도록 하는 것은 팀의 역량을 강화하고 조직의 성장을 촉진하며 직원 참여도, 경험 및 생산성을 개선하기 위한 중요한 과제이다.

디지털서비스 이슈리포트

인재 데이터에 쉽고 안정적으로 액세스할 수 없다면 관리자는 본능에 의존할 수밖에 없다. 그러나 이제 데이터가 성공의 핵심 동력이 된 만큼, CHRO는 직관과 데이터 사이의 간극을 좁히기 위해 노력해야 한다. 관리자의 인사이트와 의사 결정의 정확성을 높여주는 도구를 통해 관리자의 역량을 강화해야 한다. 이러한 접근 방식은 직감을 강화하는 동시에 잘못된 경험적 인식을 수정할 수 있다. 관리자의 의사 결정 방법론에는 데이터 기반 인사이트와 경험적 관찰이 적절히 균형을 이루어야 한다.

모든 직원이 데이터 과학자가 되기를 기대할 수도 없고, 일반 직원이 기본적으로 데이터 해독 능력을 갖추기를 기대할 수도 없다. 그러나 기업이 더 나은 의사 결정을 위해 데이터 활용을 강화하고자 한다면, 데이터 사용 및 해석 방법에 익숙해야 하는 직원의 역할 또는 범주를 파악해야 한다. 데이터에 대한 회사의 전략적 맥락을 이해하거나, 셀프서비스 도구를 사용하고, 대시보드를 파악하는 데이터 해석 능력은 지속적인 학습 여정을 의미한다. 그러기 위해 조직은 데이터 민주화의 우선순위를 높여야 한다. 다양한 관리자 역할 간의 데이터 접근성 격차를 고려하면 자율적인 데이터 액세스의 필요성은 더욱 분명하다. 접근성의 차이는 데이터 민주화를 고위 경영진을 넘어 모든 수준의 리더십으로 확대하는 것이 중요하다는 점을 강조한다. 이 단계는 공평한 접근을 보장하고 직위, 부서, 연차와 관계없이 모든 관리자가 적시에 정확한 데이터를 기반으로 정보에 입각한 의사 결정을 내릴 수 있도록 지원한다.

에어비앤비에서는 데이터 전문가, 관리자, 초보자라는 세 가지 페르소나를 통해 데이터 인식, 데이터 수집 및 시각화, 대규모 데이터의 세 가지 숙련도 수준에 따라 모든 직원을 교육하는 데이터 유니버시티⁹⁾를 만들었다. 콘텐츠는 독립형 비즈니스 단위의 특정 데이터 집합과 요구 사항에 맞춰져 있다. 현직자들이 일반적으로 교육을 제공하기도 하지만, 이는 선택 사항이고 직원의 실제 사업부 및 기능적 맥락을 벗어난 데이터 해독 능력과 데이터 콘텐츠에 주로 초점을 맞추고 있다.

Data University Vision



그림 10 에어비앤비 데이터유니버시티의 비전 (출처: 에어비앤비)

9) Getcensus, "How Airbnb democratized their data to empower their employees", Oct 13, 2020

디지털서비스 이슈리포트

마무리

기업의 관리자는 더 많은 인사 데이터의 효율적 활용을 위해 생성형 AI를 사용할 시기가 되었다. 데이터 분석을 위해 CHRO는 생성형 AI를 더 효과적으로 지원하고, 의사 결정을 개선하고, 인재를 육성 및 유지하며, 조직 전반에서 효과적인 변화 관리 역량을 강화하는 도구로 사용할 수 있다.

인사 데이터 민주화는 관리자가 사람 관련 데이터를 더 효과적으로, 그리고 더 자주 활용할 수 있도록 하는 핵심 요소이고, 자동화는 현재까지의 관리자의 의사 결정 방법론을 재정의하고 모범 사례를 시대와 기술에 발맞춰 업데이트하는 데 있어 놓칠 수 없는 요소일 수 있다. 직관적인 대화형 인터페이스를 통해 셀프서비스 기능을 혁신하고 인력 분석에 대한 액세스를 가속하여 인력 인사이트에 대한 접근성을 높이고 시각적 표현과 명확한 내러티브 응답을 결합하여 전문 지식과 관계없이 모든 인사 리더가 복잡한 쿼리를 손쉽게 탐색할 수 있어야 한다. 슬랙이나 팀즈에 통합되어 일상적인 워크플로우에 원활하게 동작하여 사용자가 손쉽게 인사이트를 얻을 수 있도록 지원할 수 있어야 한다. 사람이 중요하다는 것이 데이터로 보이고 그것에 따라 합리적 결정이 이루어지는 AI와의 조화로운 관계에서 기업의 경쟁력이 다시 한번 빛날 것으로 전망한다.

03 클라우드에서 서비스 확장하기

| 정채상 인이지 연구소 기술 책임자

들어가며

지난 2024년 8월호에 “클라우드 서비스 개발에서 데이터베이스 사용 최적화하기”라는 주제로 클라우드에서 서비스를 운영하고 있으면서 사용자가 늘어날 때 데이터베이스를 이용하면서 생기는 여러 이슈에 대해서 어떻게 그 문제들을 다루는지를 여러 가지 방법들을 다루었습니다.

마지막 문단에는 서비스를 운영하는 여러분들이 이 단계까지 오게 되면 많은 사용자들이 이용하고 있다는 증거이므로 먼저 축하의 마음을 전한다는 말과 함께 데이터베이스 이외에도 다양한 문제들이 발생할 것임을 이야기해 드렸는데, 이 글에서는 데이터베이스 최적화만으로 해결되지 않는 다양한 이슈들에 대해 각종 클라우드 환경에서 어떤 노력을 할 수 있는지에 대해 이야기해 보겠다.

앞글에서는 데이터베이스의 최적화 기법들에 관해 이야기하기 위해서 게시판을 운영하는 서비스의 예를 들었지만, 이 글에서는 조금 더 일반적인 서비스에 동시에 접속하려는 사용자가 많아져서 발생하는 이슈들에 관해 이야기해 보겠다. 타임 딜 같은 외부 이벤트 등과 연계해서 사용자들이 늘어나는 것을 예상할 수도 있고, 이른바 자발적 소문 마케팅에 긍정적 영향을 받아서 예상하지 못하는 상태에서 점진적으로 사용자들이 늘어나는 경우도 있을 수 있겠다.

동시 접속 처리 - 웹 서비스

게임과 같은 앱을 운영하더라도, 클라우드에 있는 서버에 접속해서 서비스를 시작할 것이고, 이는 웹 서비스에 동시에 많은 사용자들이 몰리는 것과 같기에 웹 서비스를 만들 때 어떻게 하면 동시 접속할 수 있는 사용자를 늘릴 수 있을 까와 같은 문제라 하겠다. 사용자가 직접 하나의 기계를 선택해서 거기서 실행되고 있던 웹 서버에 연결해서 요청하던 환경에서 아래와 같이 확장을 고려할 수 있다. 그림 1은 네이버 클라우드에서 레퍼런스로 보여주는 소규모 웹사이트를 위한 아키텍처의 사례이고, 여러 개의 웹 서버가 나눠서 사용자의 요청에 대응하는 모습이다. 그리고 그림 2는 마이크로소프트 애저에서 제공하는 앱 서비스를 이용해서 주 요청을 담당하게 하고, 나머지 필요한 요소들을 주변에 배치함으로써 확장을 구현한 모습의 사례이다.

디지털서비스 이슈리포트

소규모 웹사이트




그림 11 소규모 웹사이트를 위한 아키텍처




그림 12 기본 Azure 앱 Service 아키텍처

이는 하나의 물리적 기계 서비스에 몰려 있던 것들을 각 기능에 맞게 나누어 쓰는 것에 해당하는데, 먼저 데이터베이스를 별도의 기계 혹은 서비스로 놓고, 서비스에 필요한 파일들을 다른 곳에 놓음으로써 웹 서비스는 주어진 트래픽의 처리를 전담하게 한다.

10) <https://www.ncloud.com/intro/architecture/3>

11) <https://learn.microsoft.com/ko-kr/azure/architecture/web-apps/app-service/architectures/basic-web-app>

디지털서비스 이슈리포트

웹 서비스의 성능 개선을 위해서는 트래픽 분산을 담당하는 로드밸런서를 사용자와 웹 서버 사이에 놓으며, 유사시에 같은 기능을 하는 웹 서버를 여러 개 놓아서 동시에 운영할 수 있도록 하고, 캐시를 사용하는 등 여러 기법을 사용함으로써 성능 개선을 기대한다. 참고로 데이터베이스를 사용하지 않는 작업은 분산되는 효과를 기대할 수 있지만, 사용자들의 요구가 모두 데이터베이스를 읽고 쓴다면 병목은 다시 데이터베이스 내에서 생기게 된다.

로드 밸런서 사용하기

로드 밸런서는 여러 대의 서버에 걸쳐 있는 네트워크 트래픽을 효과적으로 분산시키는 장치로, 주요 기능은 다음과 같다.

- 트래픽 분산: 클라이언트의 요청을 여러 대의 서버에 분산시켜 서버 부하를 균형 있게 조절할 수 있고, 이를 통해 서버 리소스를 효율적으로 활용할 수 있다.
- 서버 가용성 관리: 서버의 상태를 모니터링하고, 서버가 오프라인이 되면 해당 서버를 제외하고 나머지 서버로 트래픽을 전달하는데, 이를 통해 시스템의 가용성과 신뢰성을 높일 수 있다.
- 확장성 지원: 서버 용량을 동적으로 늘리거나 줄일 수 있어, 시스템의 확장성을 높일 수 있다.
- 보안 기능: SSL 종단 암호화, 웹 애플리케이션 방화벽(WAF, Web Application Firewall) 등 다양한 보안 기능을 제공하여 시스템의 보안을 강화할 수 있다.
- 세션 관리: 사용자 세션을 관리하여 동일한 클라이언트 요청이 동일한 서버로 전달되도록 할 수 있다.

이와 같은 기능을 통해 로드 밸런서는 웹 서버와 사용자 사이뿐 아니라 API 서비스, 데이터베이스 등 다양한 분야에서 활용되고 있고, 대규모 트래픽을 처리하는 시스템에서 로드 밸런서는 매우 중요한 역할을 한다. 클라우드 환경에서는 아래와 같은 다양한 로드 밸런서 솔루션들을 사용할 수 있다.

- AWS ELB(Elastic Load Balancing)¹²⁾ AWS에서 제공하는 기본 로드 밸런서로, 다양한 유형을 선택 가능하고 글로벌 네트워크 및 강력한 보안 기능들을 통합할 수 있다.
- 애저 Load Balancer¹³⁾: 애저에서 제공하는 기본 로드밸런서로 L4 로드 밸런싱 외에 웹 애플리케이션 방화벽(WAF)과 통합된 보안 기능을 제공한다.
- GCP Load Balancing¹⁴⁾: 구글 클라우드에서 제공하는 관리형 로드 밸런서로, 단일 글로벌 IP로 전 세계에서 트래픽 처리가 가능하고, 자동으로 확장과 트래픽 최적화를 지원한다.

12) <https://aws.amazon.com/elasticloadbalancing/>

13) <https://learn.microsoft.com/en-us/azure/load-balancer/load-balancer-overview>

14) <https://cloud.google.com/load-balancing?hl=ko>

디지털서비스 이슈리포트

- NCP Load Balancer¹⁵⁾: 네이버 클라우드에서 제공하는 로드 밸런서로, 비용 효율적이며, 사용자가 정의 가능한 로드 밸런싱 정책을 제공한다.
- NGINX¹⁶⁾ / HAProxy¹⁷⁾: 오픈 소스 웹 서버이자 리버스 프록시로, 트래픽을 분산시키는 로드 밸런서로 사용할 수 있다. 설치형으로 주로 이용한다.

캐시 사용하기

먼저 캐시는 컴퓨터 과학에서 일반적으로 쓰이는 개념으로 자주 사용하는 데이터 혹은 앞으로 사용할 거 같은 데이터에 빠르게 접근할 수 있는 곳에 준비하는 방법론을 이야기한다. 하드웨어부터 응용 소프트웨어까지 널리 쓰이는 기법으로 시스템의 성능을 높이고 응답 시간을 단축하기 위해 광범위하게 사용된다.

하나의 웹 서비스를 사용자들이 실행하는 데 네트워크를 통해서 여러 서비스를 이용하게 될 때도 같은 개념을 다양한 계층에서 사용할 수 있다. 각 계층에서 메모리를 소비하고 임시적인 데이터 일관성을 비용으로 지불하면서 전체 응답 시간 단축, 서버의 부하 감소를 기대하고, 그에 따른 비용 절감의 효과까지도 이를 수 있다. 아래는 계층별로 자주 캐시를 사용하는 방법들의 예제들이다.

- 브라우저 캐시 : 사용자 브라우저에서 캐시를 설정해서 이미지, CSS, JS 파일 등을 저장해 두어 다음번 요청 시 네트워크를 이용하지 않고 빠르게 로드 할 수 있게 할 수 있다.
- 리버스 프록시 캐시 : 로드 밸런서로 사용하는 리버스 프록시의 경우 각 클라이언트에서의 요청과 백엔드 서버의 응답을 저장해 두고 같은 요청에 같은 결과는 네트워크를 이용하지 않고 사용할 수 있다.
- 서버 사이드 캐시 : 서버 내에서 자주 사용하는 데이터를 매번 연산하지 않고, 메모리 등에 저장하여 사용한다.
- 데이터베이스 쿼리 캐시 : 데이터베이스에서 자주 조회되는 쿼리 결과를 저장해서 데이터베이스의 추가적인 열람을 하지 않고 성능을 높인다.

이들 중 클라우드 환경에서 동작하는 서비스에서 사용하는 캐시는 서버 사이드 캐시에 해당하고, 서버에서의 다양한 지원을 위해서는 레디스(Redis)와 멤캐시드(Memcached)를 인메모리(in-memory) 데이터 저장소로 주로 사용한다. 다양한 데이터 구조와 보조 장치에 기록해야 할 경우 혹은 메시지 전송

15) <https://www.ncloud.com/product/networking/loadBalancer>

16) <https://nginx.org/en/>

17) <https://www.haproxy.org/>

디지털서비스 이슈리포트

기능이 필요할 때는 레디스 계열이 주로 이용되고, 단순한 키-값 캐시가 필요하고 상대적으로 더 빠른 성능이 필요할 때는 멤캐시드 계열 서비스를 사용한다.

	Memcached	Redis OSS
1밀리초 미만의 지연 시간	예	예
개발자 사용 편의성	예	예
데이터 파티셔닝	예	예
다양한 프로그래밍 언어 지원	예	예
고급 데이터 구조	-	예
다중 스레드 아키텍처	예	-
스냅샷	-	예
복제	-	예
트랜잭션	-	예
게시/구독	-	예
Lua 스크립팅	-	예
지형 정보 지원	-	예

18)

그림 13 레디스 OSS와 멤캐시드 중에서 선택하기

캐시 서비스를 설치해서 사용할 수도 있지만, 클라우드 서비스에서는 아래와 같이 관리형 서비스들을 사용할 수 있다.

- AWS¹⁹⁾ : 아마존 엘라스틱캐시(Amazon ElastiCache)는 관리형 캐시 서비스로, 레디스와 멤캐시드를 지원한다.
- 구글 클라우드²⁰⁾: 구글 클라우드 메모리스토어(Google Cloud Memorystore)는 관리형 캐시 서비스로, 레디스와 멤캐시드, 발키(Valkey), 레디스 클러스터 등을 지원한다.
- 애저²¹⁾: 애저 캐시 포 레디스2(Azure Cache for Redis®2)는 관리형 캐시 서비스로 레디스를 지원한다.
- 네이버 클라우드²²⁾ : 클라우드 DB 포 레디스(Cloud DB for Redis)는 관리형 캐시 서비스로 레디스를 지원한다.

18) https://aws.amazon.com/ko/elasticache/redis-vs-memcached/?nc1=h_ls

19) <https://aws.amazon.com/ko/pm/elasticache>

20) <https://cloud.google.com/memorystore?hl=ko>

21) <https://azure.microsoft.com/en-us/products/cache>

22) <https://www.ncloud.com/product/database/cloudDbRedis>

디지털서비스 이슈리포트

CDN 사용

앞에서 이야기한 사용자와 서비스 사이의 캐시를 구현하는 방법의 하나로 CDN(콘텐츠 전송 네트워크, Content Delivery Network)이 많이 쓰인다. 이는 콘텐츠를 더 빠르고 효율적으로 전달하기 위한 분산 네트워크이고, 이 CDN은 여러 서버로 구성된 네트워크를 통해 웹사이트의 정적 자원(이미지, 비디오, CSS, JavaScript 파일 등)을 사용자와 가장 가까운 서버에서 제공함으로써 웹사이트의 성능과 가용성을 향상한다.

클라우드 서비스들이 실제 사용자에게 쓰일 때 영향이 큰 부분이기도 하고, 퍼블릭 클라우드가 널리 쓰이기 이전부터 중요하게 쓰였으며, 현재 아래와 같은 여러 서비스가 있다.

- 아카마이(Akamai) ²³⁾
 - 업계에서 가장 오래된 CDN 중 하나로, 전 세계적으로 분산된 데이터 센터를 보유하고 있다.
 - 높은 가용성과 안정성을 제공하며, 광범위한 보안 기능(DDoS 방어, WAF 등)들을 제공한다.
- 클라우드플레어(Cloudflare) ²⁴⁾
 - 무료 플랜을 제공하는 인기 있는 CDN으로, 설정이 간편하다.
 - DDoS 방어, SSL, WAF 등 다양한 보안 기능을 포함하고 있으며, 빠른 속도와 안정성을 제공해서 중소기업, 스타트업 혹은 개인 웹사이트에도 많이 사용된다.
- 아마존 클라우드프론트(Amazon CloudFront) ²⁵⁾
 - AWS 생태계에 통합된 CDN 서비스로, AWS의 다양한 서비스와 원활하게 연결된다.
 - 유연한 요금 체계와 높은 확장성을 제공하며, 글로벌 엣지 로케이션을 통해 빠른 속도를 보장한다.
- 구글 클라우드 CDN(Google Cloud CDN) ²⁶⁾
 - 구글 클라우드 플랫폼에 통합되어 제공되는 CDN으로, 구글 클라우드의 인프라를 활용한다.
 - 자동화된 캐싱, HTTPS 지원을 비롯한 구글 클라우드 서비스와의 원활한 통합이 가능하다.
- 애저 CDN ²⁷⁾
 - 애저 플랫폼과 통합된 CDN 서비스로, 다양한 콘텐츠 전송 및 캐싱 기능을 제공한다.
 - 애저의 보안 및 데이터 관리 기능과 함께 사용하여 안정성을 높일 수 있다.

23) <https://www.akamai.com/>

24) <https://www.cloudflare.com/>

25) <https://aws.amazon.com/ko/cloudfront/>

26) <https://cloud.google.com/cdn?hl=ko>

27) <https://azure.microsoft.com/en-us/products/cdn>

디지털서비스 이슈리포트

- CDN+ 28)

- 네이버 클라우드 플랫폼에 통합되어 제공되는 CDN이다.
- 한국 내 사용자에게 최적화된 성능을 제공하며, DDoS 방어와 자동 캐시 관리 기능이 뛰어나다.

그 밖의 기법들

이제까지 더 많은 동시 접속 사용자를 지원하기 위해 클라우드에서 지원하는 서비스를 이용해서 해결하려는 방법들에 대해 알아보았고, 그 이외에도 몇 가지 방법들을 소개한다. 어떤 방법을 적용하기 전에 이미 끊임없는 모니터링과 최적화 등을 고민해야 하고, 병목이 일어나고 있는 건 아닌지, 네트워크 전송 속도와 CPU의 부하 등을 계속 체크해야 한다.

먼저 해당 기계들의 물리적인 위치를 고려한다. 넓게는 나라, 조금 좁게는 데이터 센터의 위치, 더 좁게는 네트워크 장비까지 클라우드 내에서 서비스들의 위치들까지 불필요한 낭비가 없는지 확인한다. 흔히 하는 실수로, 잘 동작하고 있던 서비스가 몇 명의 사용자가 쓰지 않는 기능을 위해 작은 새로운 서비스가 연동되면서 병목이 되어 전반적으로 느려지는 경우가 있곤 한다. 클라우드 내에서라도 네트워크 대역이 충분히 활용되고 있는지 확인하도록 한다.

그리고, 개발자들 사이에서 종종 이슈로 오가는 CSR(클라이언트 측 렌더링, Client-Side Rendering)과 SSR(서버 측 렌더링, Server-Side Rendering) 사이의 선택도 고려할 수 있다. 사용자의 여러 행동들을 매번 서버에 물을 것인가, 미리 받아 놓은 코드로 해결할 것인가의 선택지로, 사용자와 서비스 사이의 불필요한 통신을 줄이는 요소가 될 수 있지만, 검색 엔진에 노출되기를 원하는 페이지의 경우 검색 엔진에 잘못된 정보를 전해줄 수가 있어 장단점을 비교할 수 있어야 한다.

마지막으로 하나의 요청과 응답을 주고받게 될 때 더 많은 동시 접속을 지원하려면 시간이 오래 걸리는 작업을 비동기 처리를 이용해서 구현할 수 있다. 카프카(kafka)나 펄브(sub) 등의 메시징 시스템을 이용해서 서비스를 재구성해야 하지만, 시간이 오래 걸리는 작업을 시스템의 부하가 적을 때 몰아서 할 수 있으므로 시스템의 효율도 높일 수 있다. 다만, 실제 작업이 끝나기 전에 대기 중이라는 화면을 보여주는 등 사용자를 대상으로 하는 기능이 추가되어야 한다면 설계를 다시 해야 하는 경우가 생기기도 하니, 여건을 고려해서 적절한 방법을 선택해야 한다.

아래는 이제까지의 기법들이 적용된 서비스의 조금 복잡한 설계 예제이다. 가운데 웹 서버를 중심으로 이 글을 시작할 때보다 많은 고려할 것들이 추가되어 있음을 알 수 있다.

28) <https://www.ncloud.com/product/contentDelivery/cdn>

디지털서비스 이슈리포트





그림 14 AWS 클라우드에서의 웹 애플리케이션 호스팅

29) https://docs.aws.amazon.com/ko_kr/whitepapers/latest/web-application-hosting-best-practices/an-aws-cloud-architecture-for-web-hosting.html

디지털서비스 이슈리포트

동시 접속 처리 - 컨테이너를 이용한 배포

클라우드에 만들어진 서비스들은 여러 개의 논리적인 애플리케이션 서비스에서 처리가 되는데 아래 그림처럼 이전의 전통적인 방식에서는 하나의 운영체제 위에 여러 개의 서비스가 동작하는 방식이었다면, 이후 데이터 센터 혹은 클라우드를 사용하는 지금은 가상화된 배포 시대를 지나 컨테이너를 개발해서 배포하는 시대로 바뀌어 가고 있다. 중간에 VM이라 부르는 가상화된 하드웨어 상에서 자체 운영체제를 포함한 형태로 자원을 나누어 쓰는 시도들이 있었지만, 운영체제를 여러 계층으로 운영하는 것보다 하나의 운영체제에 런타임 환경을 나누고 공유할 수 있게 하는 컨테이너 방식이 지금은 대세로 자리 잡고 있다.



30)

그림 15 어플리케이션 배포 환경의 변화

컨테이너는 아래와 같은 이유로 널리 쓰이게 되었다.


- 기민한 애플리케이션 생성과 배포: VM 이미지를 사용하는 것에 비해 컨테이너 이미지 생성이 더욱 쉽고 효율적이다.
- 지속적인 개발, 통합 및 배포: 안정적이고 주기적으로 컨테이너 이미지를 빌드해서 배포할 수 있고 빠르고 효율적으로 롤백할 수 있다.
- 개발과 운영의 관심사 분리: 배포 시점이 아닌 빌드/릴리스 시점에 애플리케이션 컨테이너 이미지를 만들기 때문에, 애플리케이션이 인프라스트럭처에서 분리된다.
- 가시성(observability): 운영체제 수준의 정보와 메트릭에 머무르지 않고, 각 애플리케이션의 상태와 그 밖의 시그널을 모아볼 수 있다.

30) <https://learn.microsoft.com/ko-kr/azure/architecture/web-apps/app-service/architectures/basic-web-app>

디지털서비스 이슈리포트

- 클라우드 및 OS 배포판 간 이식성: 우분투, RHEL, CoreOS, 온-프레미스, 주요 퍼블릭 클라우드와 어디에서든 구동된다.
- 분산되고, 유연하며, 자유로운 마이크로서비스: 애플리케이션은 단일 목적의 머신에서 모놀리식 스택으로 구동되지 않고 더욱 작고 독립적인 단위로 쪼개져서 동적으로 배포되고 관리될 수 있다.

이때 하나의 서비스를 앱으로, 배포와 운영의 단위로는 컨테이너, 그들이 공유하는 전통적인 하드웨어와 OS에 접근하게 해 주는 컨테이너 런타임을 사용하고, 이들을 아울러서 함께 운영하는 방식으로 쿠버네티스(kubernetes)를 널리 쓴다. 이는 오래전 구글의 보그³¹⁾(borg)라는 관리 프로그램이 오픈 소스로 세상에 공개된 후 일반적으로 쓰이게 된 것으로 아래 그림처럼 컨테이너화된 애플리케이션을 실행하는 역할을 하는 노드, 이들이 모여 있는 노드 클러스터, 하나 이상의 컨테이너가 모여 구성된 파드(Pod) 등의 개념으로 일들을 수행할 서버들을 조율한다. 그래서 쿠버네티스는 가장 유명한 컨테이너 오케스트레이션 서비스라고 부른다.



32)

그림 16 쿠버네티스 개요

쿠버네티스를 이용하면, 계획적으로 혹은 동적으로 서비스들을 관제할 수 있고, 자원 분배도 효율적으로 할 수 있다. 특히 클라우드 환경에서 자원의 구매 방식에 따라 다양한 전략을 구사할 수 있기에 클라우드 고객들은 직접 쿠버네티스 클러스터 등을 운영할 수도 있고, 반대로 각 클라우드 서비스들은 이런 편의를 위해 각각 아래와 같은 관리형 서비스들을 운영한다.

- AWS EKS(Elastic Kubernetes Service)
 - AWS에서 제공하는 완전 관리형 쿠버네티스 서비스
 - AWS의 EC2와 Fargate와 통합하여 다양한 워커 노드 옵션 사용 가능
 - 다양한 AWS의 서비스들과 깊이 있게 통합되어 있음

31) <https://kubernetes.io/blog/2015/04/borg-predecessor-to-kubernetes/>

32) <https://kubernetes.io/docs/tutorials/kubernetes-basics/explore/explore-intro/>

디지털서비스 이슈리포트

- GCP GKE(Google Kubernetes Engine)
 - 구글 클라우드가 제공하는 완전 관리형 쿠버네티스 서비스
 - 최신 쿠버네티스 기술이 빠르게 반영
 - 구글 클라우드 로드 밸런서, 클라우드 모니터링, 클라우드 로깅과 통합되어 있음
 - 앤토스와 통합을 통해 온-프레미스 및 멀티 클라우드에서 일관된 관리 가능
- 애저 AKS(Azure Kubernetes Service)
 - 애저에서 제공하는 완전 관리형 쿠버네티스 서비스
 - 애저의 VM, ACI(Azure Container Instance)와의 통합으로 유연한 워커 노드 배포 가능
- 네이버 클라우드 쿠버네티스 서비스
 - 네이버 클라우드에서 제공하는 쿠버네티스 관리형 서비스로, 한국 기반의 로컬 클라우드 환경에서 최적화된 솔루션
 - 국내 클라우드 환경에 최적화되어 있어 한국에서 법적 요구 사항을 충족하는 데 유리함
- IBM 클라우드 쿠버네티스 서비스
 - IBM 클라우드에서 제공하는 완전 관리형 쿠버네티스 서비스
 - 하이브리드 클라우드 및 멀티 클라우드 전략에 특화되어 있음.

아이러니하게 클라우드에 독립적인 환경을 더 잘 사용하기 위해 특정 클라우드와의 종속성을 늘어나는 방향으로 진행되는데, 로깅 같은 클라우드 내의 다른 서비스들과 연결이 쉽거나 자동으로 자원을 할당하거나 하는 등의 장점이 있고, 이로 인한 자원의 효율성 향상으로 인해 비용이 절감되기도 한다.

컨테이너 혹은 컨테이너 클러스터를 운영할 때 가장 흔하게 하는 실수는 할당받아 놓고 쓰지 않는 유휴 자원들로 인한 낭비와 손실인데, 클라우드 단위의 관리형 서비스들은 개별 업체가 아니라 전체 클라우드상에서 쓰지 않는 리소스들을 미리 반납하는 형태로 클라우드 업체가 얻는 이득을 나눠 갖는 방식으로 구현된다. 다만 자원의 사용률이 이미 어느 정도 이상으로 이미 쓰고 있다면 거꾸로 다양한 방법으로 자원들을 선점해서 싸게 선구매한 후에 쿠버네티스 클러스터를 직접 운영하는 식으로 비용 절감을 구현하기도 한다. 서비스가 장기적인 성장이 예상될 때 고민과 결정이 필요한 순간이 오게 될 것이다.

디지털서비스 이슈리포트

맺으며

지금까지 클라우드에서 만든 서비스들이 사용자가 늘어 확장할 때 발생하는 이슈 중에서 어플리케이션 단에서 일어나는 일들과 이들을 대응하기 위한 여러 시도, 그중에서 클라우드 서비스에서 사용 가능한 방법들을 위주로 정리하여 보았다. 데모 시스템을 간단하게 운영하던 시작에 비해서 아주 많은 부가적인 서비스들을 익히고 이용해야 하지만, 안정적인 서비스로 가는 필연적인 과정들이다.

시스템을 확장하는 과정에서 새로운 역할들을 하는 서비스들이 필요한데, 많은 경우 각 퍼블릭 클라우드 혹은 로컬 클라우드에서 제공하고 있거나 서드파티의 형태로 사용을 할 수 있다. 그리고 여러 신기술을 적용하는 새로운 서비스들이 생기고 가끔 없어지기도 한다. 기술 책임자의 시각에서는 각 클라우드 내에서 사용할 수 있는 서비스들의 기능, 제약, 가격, 락인 효과, 심지어 직원들의 친숙도 등을 고려해서 결정을 끊임없이 내려야 하겠고, 다시 한번 그 무게와 책임을 응원한다.

